

TIAD_projet

Yu Zigong et Happy Hugo

26 fevrier 2020

```
library('MASS')
```

1)

On fera le test suivant:

H0: les log-returns sont centrés,
contre H1: les log-returns ne sont pas centrés.

La Statistique de test : $Tn = \sqrt{n} \frac{\bar{X}_n}{\sqrt{V_n^*}}$. où \bar{X}_n est la moyenne de SP, V_n^* est la variance empirique corrigée de SP.

Sous H0, Tn suit une loi normale $\mathcal{N}(0, 1)$ asymptotiquement.

Sous H1, Tn est plus loin de 0 que sous H0.

On fera un test bilataire symétrique, donc la zone de rejet est de forme $\{|Tn| \geq k\}$, $k = \Phi^{-1}(0.995)$, où Φ est la fonction de répartition de la loi $\mathcal{N}(0, 1)$.

```
qnorm(0.995) # On calcule k
```

```
## [1] 2.575829
```

La zone de rejet au niveau de 1% $R = \{|Tn| \geq 2.576\}$.

```
SP <- SP500 # On stocke SP500 dans SP
n=length(SP) # n est la longueur de SP
Tn = sqrt(n)*mean(SP)/sqrt(var(SP));Tn # On calcule la statistique Tn
```

```
## [1] 2.545345
```

On a calculé $Tn = 2.545 \notin R$, donc on conserve H0 au niveau 1%, les log-returns sont bien centrés.

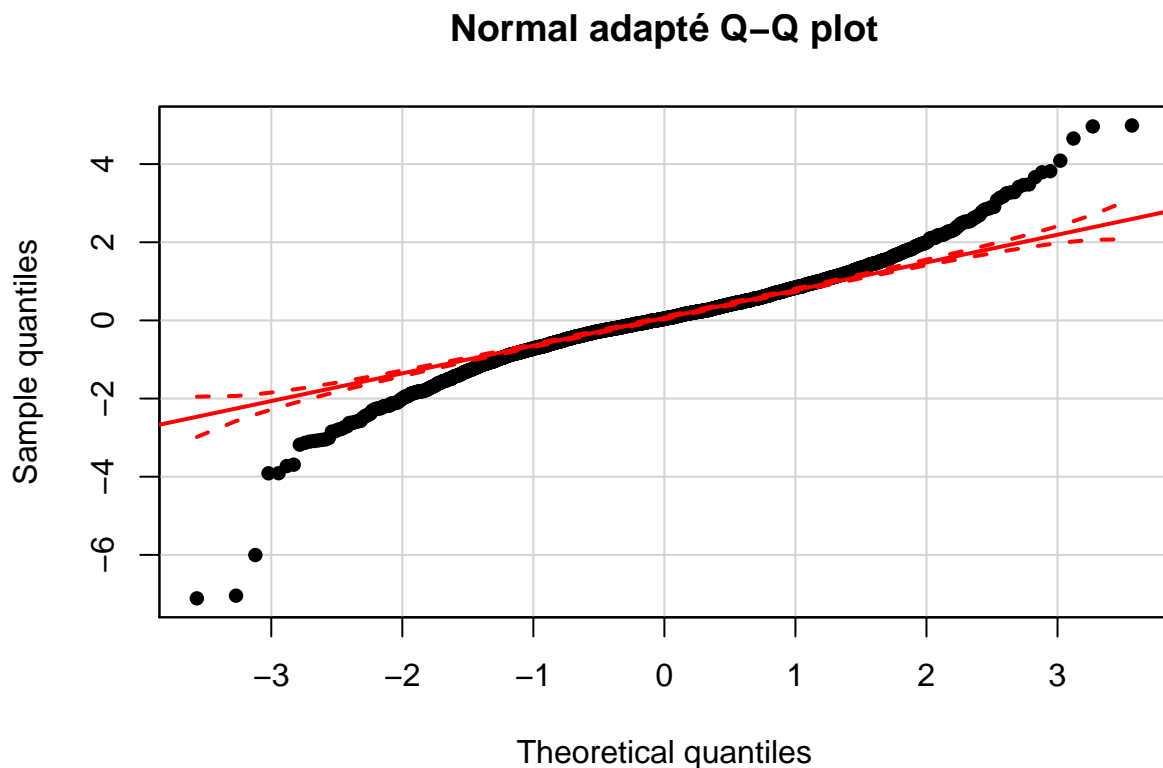
```
(1-pnorm(abs(Tn),0,1))*2 # on calcule la p-valeur
```

```
## [1] 0.01091698
```

p-valeur = 0.011.

2)
(a)

```
# On fait le qq-plot avec la fonction qqPlot dans le package car!  
library('car')  
qqPlot( SP,distribution = "norm" ,main = "Normal adapté Q-Q plot",  
        xlab = "Theoretical quantiles", ylab = "Sample quantiles",  
        col.lines='red',pch=16,id=FALSE)
```



On voit que les queues de distribution sont plus dispersées.

(b)

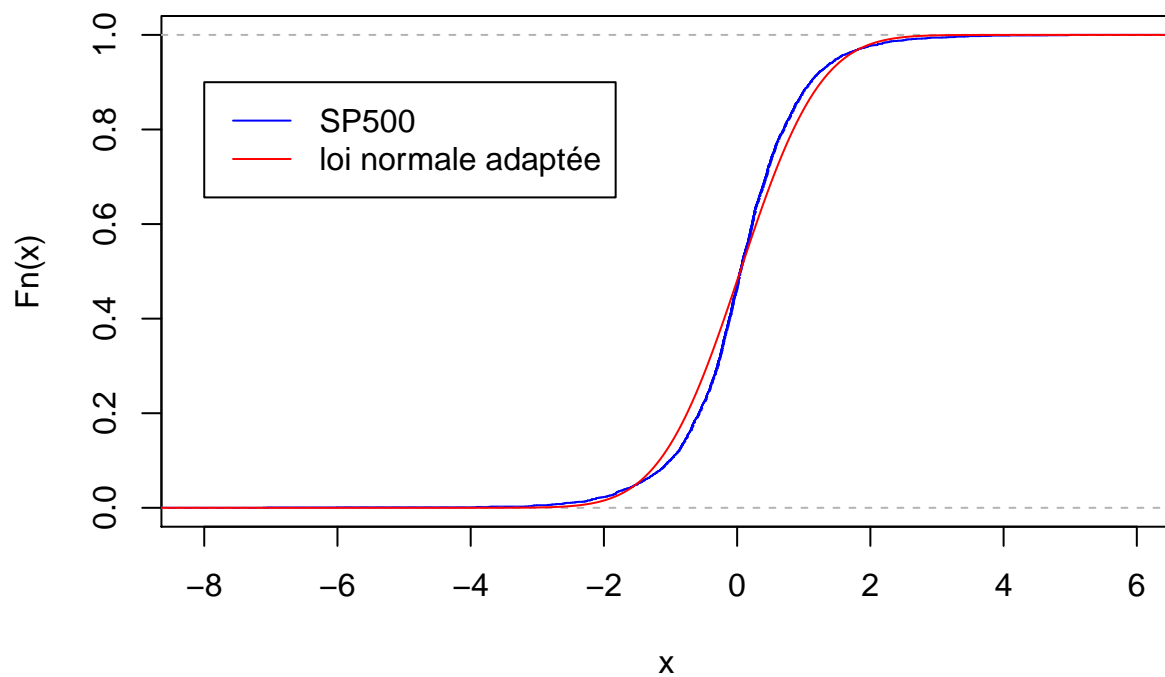
Ici, pour tracer la fonction de répartition de la loi normale adaptée de SP, on doit calculer les estimateurs des paramètres de loi normale $\mathcal{N}(m, \sigma^2)$, en plus par 1), SP est bien centré, donc $m=0$ et on estimera la variance de la loi normale.

On obtient les estimateurs de la loi $\mathcal{N}(0, \sigma^2)$: $\hat{\sigma}_n^2 = Vn^*$, Vn^* est la variance empirique corrigée de SP.

```
# On plot la fonction de répartition empirique de SP500 et sa loi  
# normale adaptée.  
plot(ecdf(SP),col='blue',  
      main="Fonction de répartition de SP500 et de sa loi normale adaptée")  
I <-seq(-10,7,length=1000)
```

```
lines(I,pnorm(I,mean(SP),sqrt(var(SP))),col='red')
legend(-8,0.9, legend=c("SP500","loi normale adaptée"),
       col=c("blue","red"),lty=1,cex=1)
```

Fonction de répartition de SP500 et de sa loi normale adaptée



```
library('nortest')
# On fait le test lillie pour tester si SP500 suit loi normale.
lillie.test(SP)

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  SP
## D = 0.064218, p-value < 2.2e-16
# On fait le test Anderson-Darling pour tester si SP500 suit loi normale.
ad.test(SP)

##
##  Anderson-Darling normality test
##
## data:  SP
## A = 23.364, p-value < 2.2e-16
```

```
# On fait le test Shapiro-Wilk pour tester si SP500 suit loi normale.  
shapiro.test(SP)
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  SP  
## W = 0.95511, p-value < 2.2e-16
```

Le test de Lilliefors est moins performant lorsque les queues de distribution empiriques s'éloignent des queues théoriques. Le test d'Anderson-Darling lui donne plus d'importance aux queues de distributions. Le test de Shapiro-Wilk est plus performant pour les faibles effectifs.

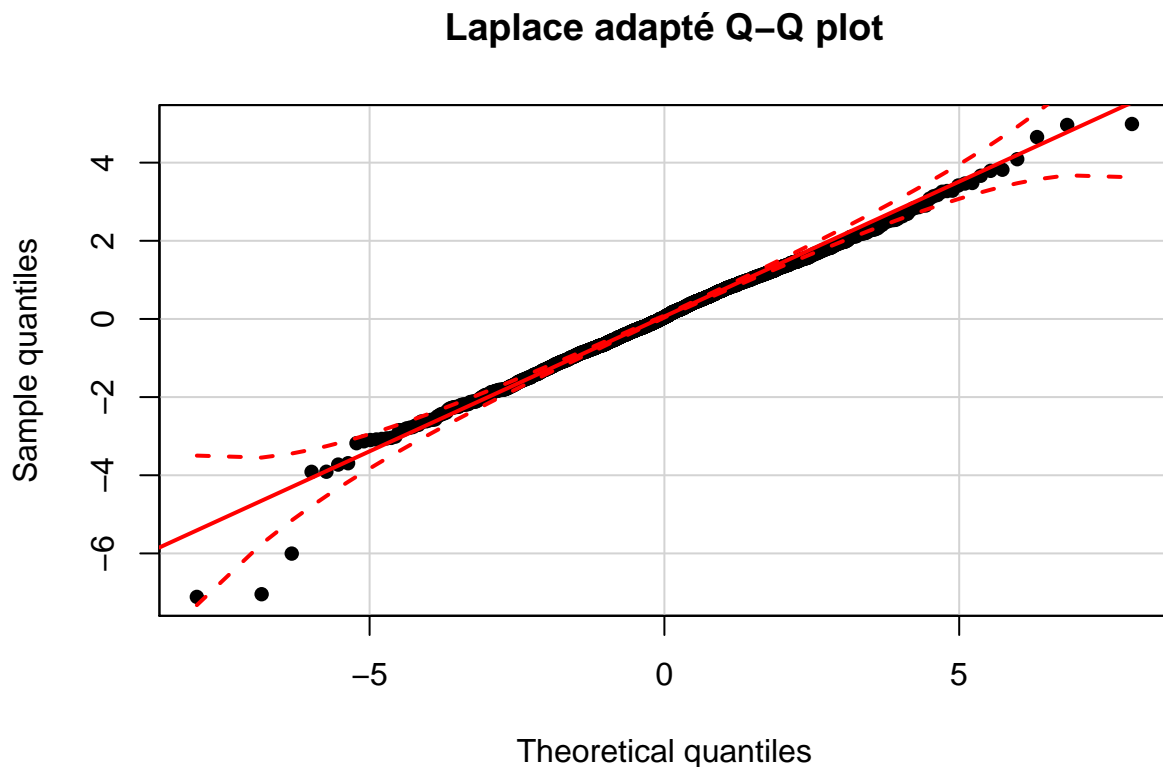
Ici, on a des queues de distribution empiriques qui s'éloignent de la théorie et un fort effectif (2780 données). Donc le test d'Anderson-Darling semble être le plus pertinent.

Cependant, les trois tests donnent la même p-valeur nulle, donc, on rejette H_0 et décide que SP500 ne suit pas une loi normale.

3)

(a)

```
#On utilise le package LaplacesDemon.
library('LaplacesDemon' )
qqPlot( SP,distribution = "laplace" ,main = "Laplace adapté Q-Q plot",
        xlab = "Theoretical quantiles", ylab = "Sample quantiles",
        col.lines='red',pch=16,id=FALSE)
```



#On voit que les queues de distribution sont moins dispersées.

(b)

$|X| \sim \text{Exp}(\lambda)$

preuve:

La densité de X est $f(x) = \frac{\lambda}{2}e^{-\lambda|x|}$.

Pour $\forall t < 0, \mathbb{P}_\lambda(|X| \leq t) = 0$.

Pour $\forall t \geq 0, \mathbb{P}_\lambda(|X| \leq t) = \mathbb{P}_\lambda(-t \leq X \leq t) = \int_{-t}^t f(x)dx = \int_{-t}^t \frac{\lambda}{2}e^{-\lambda|x|}dx = \int_0^t \lambda e^{-\lambda x}dx = 1 - e^{-\lambda t}$.

$|X|$ suit une loi $\mathcal{E}(\lambda)$.

CQFM

(c)

Ici, pour tracer la fonction de répartition de la loi normale adaptée de SP, on doit calculer les estimateurs des paramètres de loi Laplace $Laplace(0, \lambda)$.

On calcule les estimateurs de la loi $Laplace(0, \lambda)$ par EMV:

La vraisemblance $\mathcal{L}(\underline{x}, \lambda) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{\lambda}{2} e^{-\lambda|x_i|}$.

La log-vraisemblance $L(\underline{x}, \lambda) = \log(\mathcal{L}(\underline{x}, \lambda)) = n \log(\frac{\lambda}{2}) - \lambda \sum_{i=1}^n |x_i|$.


$\frac{dL}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n |x_i| = 0 \Rightarrow \lambda = \frac{1}{n} \sum_{i=1}^n |x_i|$.

L croissant quand $\lambda \in]0, \frac{1}{n} \sum_{i=1}^n |x_i|]$ et décroissant quand $\lambda \in [\frac{1}{n} \sum_{i=1}^n |x_i|, +\infty[$.

Donc l'estimateur $\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n |x_i|$.

```
plot(ecdf(SP),col='blue',  
     main="Fonction de répartition de SP500 et de la loi Laplace adaptée")  
I <-seq(-10,7,length=1000)  
lines(I,plaplace(I,0,mean(abs(SP))),col='red')  
legend(-8,0.9, legend=c("SP500","loi de Laplace adaptée"),  
       col=c("blue","red"),lty=1,cex=1)
```

Fonction de répartition de SP500 et de la loi Laplace adaptée



On a vu que les deux courbes se sont bien proches.

Maintenant, pour tester si SP suit une loi de Laplace, on fait le test d'Anderson-Darling par rapport à la loi exponentielle puis que $X \sim Laplace(\lambda) \Leftrightarrow |X| \sim \mathcal{E}(\lambda)$.

C'est le test suivant:(On pose $X=|SP|$)

H0: X suit $\mathcal{E}(\theta)$, $\theta > 0$,
 contre H1: X ne suit pas $\mathcal{E}(\theta)$, $\theta > 0$.

On considère la statistique $W_{A,n} = n \int_{-\infty}^{+\infty} \frac{(F_n(x) - F_{\hat{\theta}_n}(x))^2}{F_{\hat{\theta}_n}(x)(1 - F_{\hat{\theta}_n}(x))} dF_{\hat{\theta}_n}$, où F_n est la fonction de répartition empirique de X . Après du calcul d'un exercice en cours, en posant $Z_i = F_{\hat{\theta}_n}(X_{(i)})$, On a :

$$W_{A,n} = \sum_{i=1}^n (-\ln(Z_i)^{\frac{2i-1}{Z_i}} - \ln(1 - Z_i)^{\frac{2(n-i)+1}{n}}) - n$$

Dans ce cas là, il y aura les échantillons nuls. Donc on les supprime pour éviter le calcul de $\ln(0)$.

La statistique de test est plus grand sous H1 que sous H0. Donc la zone de rejet R est de forme $\{W_{A,n} \geq k\}$. Dans notre cours, on a montré que sous H0 la loi de $W_{A,n}$ ne dépend de θ puisque l'on a $F_{\hat{\theta}_n}(X_i) = 1 - e^{\frac{X_i}{\hat{\theta}_n}} = 1 - e^{\frac{U_i}{\bar{U}_n}}$, où $U_i \sim \mathcal{E}(1)$, donc on peut bien calculer la zone de rejet au niveau 1%.

```
W_An_exp <- function(n){
  x <- rexp(n,1)    # simule n variables de loi E(1)
  y <- sort(x)      # on range x
  v <- c(1:n)
  y=1-exp(-y/mean(x))
  W_An=sum(-log(y)*(2*v-1)/n-log(1-y)*(2*(n-v)+1)/n)-n
  return(W_An)
}

pAD_exp <- function(n,N,a){
  W_An_N <- numeric(N)    # on crée un vecteur de taille N
  for (i in 1:N) {
    W_An_N[i]=W_An_exp(n)    #on fait N fois le calcul de W_An
  }
  S <-outer(W_An_N,a,"<=")    # on calcule et renvoie la proba empirique
  V <-colSums(S)
  return(V/N)
}

I <- seq(1,3,length=2001 )
#On calcule 3 fois k (car k est varié chaque fois )
1+min(which(1-pAD_exp(2778,1000,I)<=0.01))/1000

## [1] 1.836

1+min(which(1-pAD_exp(2778,1000,I)<=0.01))/1000

## [1] 1.868

1+min(which(1-pAD_exp(2778,1000,I)<=0.01))/1000

## [1] 2.039
```

La zone de rejet R au niveau 1% est $\{W_{A,n} \geq k\}$, où k est entre 1.8 et 2.2.

```
# Maintenant on calcule la sttistique:
x=abs(SP)
y0 <- sort(x)          # on range x
y0=1-exp(-y0/mean(x))
# Dans ce cas là, il y aura les échantillons nuls. On ne les
# teste pas.
y0=y0[y0!=0]
n=length(y0)
v <- c(1:n)
W_An=sum(-log(y0)*(2*v-1)/n-log(1-y0)*(2*(n-v)+1)/n)-n;W_An

## [1] 3.181648
```

La statitique $W_{An} = 3.182 \in R$ en ne considérant pas les valuers nulles dans SP, dans ce cas là, on rejette H_0 et déside que SP ne suit pas une loi exponentielle.

```
# On calcule la p-valeur
1-pAD_exp(2778,100000,W_An)

## [1] 0.00057
```

p-valeur=0.00054=0.054%,donc on rejette H_0 , et déside que $|SP|$ ne suit pas une loi exponentielle, c'est à dire que SP ne suit pas une loi de Laplace, mais la p-valeur de ce test est plus élevée que le test d'AD de normalité.

4)

(a)

On trace la densité estimée en utilisant notre fonctions dans TD3.

```
X=SP #On stocke SP dans X
Xmax = max(abs(X))
y =seq(-2*Xmax,2*Xmax,length= 1001)

est <- function(h,X,y){
  M3=outer(y,X,"-")
  f=rowMeans(1/h*K(M3/h))
  return(f)
}
# On choisit le noyau d'Epachnikov et le crée
K <-function(x){
  return ((3/4)*(1-x^2)*(abs(x)<=1))
}
#On crée une fonction pour calculer l'intégrale
integrale <- function(X,pas)
{
  resultat=1/2*(sum(X[2:length(X)]*pas)+sum(X[1:length(X)-1]*pas))
  return(resultat)
}
#On va minimiser risque pour trouver une meilleure fenêtre
risque <- function(h,X,y)
{
  n <- length(X)
  Gh <- mean((est(h,X,X)-(1/h*K(0))/n)*n/(n-1))
  pas = y[2]-y[1]
  CV = integrale(est(h,X,y)^2,pas)-2*Gh
  return(CV)
}
#On fait varier h entre 0 et 1 pour trouver le meilleur h à 0.1 près
CV_h <- numeric(10)
for (i in 1:10 ) {
  CV_h[i]=risque(i/10,X,y)
}
which.min(CV_h)/10

## [1] 0.3
```

La meilleure fenêtre à 0.1 près est 0.3

```

#On fait varier h entre 0.2 et 0.4 pour trouver le meilleur h à 0.01 près
CV_h1 <- numeric(20)
for (i in 1:20) {
  CV_h1[i]=risque(which.min(CV_h)/10-0.1+i/100,X,y)
}

h_min=which.min(CV_h)/10-0.1+which.min(CV_h1)/100;h_min

## [1] 0.33

```


La meilleure fenêtre à 0.01 près que l'on a obtenue est 0.33

```

fm=est(h_min,X,y)

plot(y,fm,col='red',type = 'l',xlab = "x",ylab="la densité",
     main="La densité estimée de SP")

```



(b)

```


plot(y,fm,type = 'l',xlim=c(-5,5))
x=SP

```

```

d_epa = density(x,kernel = "epanechnikov",bw='nrd');d_epa$bw
## [1] 0.1549821
d_epa0 = density(x,kernel = "epanechnikov",bw='nrd0');d_epa0$bw
## [1] 0.1315886
d_epa_ucv = density(x,kernel = "epanechnikov",bw='ucv');d_epa_ucv$bw
## [1] 0.130009
d_epa_bcv = density(x,kernel = "epanechnikov",bw='bcv');d_epa_bcv$bw
## [1] 0.1279333
d_epa_SJ = density(x,kernel = "epanechnikov",bw='SJ');d_epa_SJ$bw
## [1] 0.1249875
lines(d_epa_SJ,col='purple')
lines(d_epa_bcv,col='green')
lines(d_epa_ucv,col='orange')
lines(d_epa,col='red')
lines(d_epa0,col='blue')
legend(-5,0.5, legend=c("d_epa_SJ      h=0.125","d_epa_bcv      h=0.128",
                        "d_epa_ucv      h=0.130","d_epa_nrd      h=0.155",
                        "d_epa_nrd0     h=0.132","fenêtre_opt      h=0.33"),
      col=c("purple", "green","orange","red","blue","black"),lty=1,cex=0.8)


```



On voit que les densités estimées par les façons différentes sont bien coïncidentes grâce à la grande taille d'observations.

```
I=seq(-5,5,0.001)
plot(y,fm,type = 'l',xlim=c(-5,5),ylim=c(0,0.8),
      xlab = "x",ylab="la densté",
      main="La densté de normale adaptée et de Laplace adapté")
lines(I,dlaplace(I,0,mean(abs(SP500))),col='blue')
lines(I,dnorm(I,0,sqrt(var(SP500))),col='red')
legend(-4.9,0.7, legend=c("densité de la loi de Laplace adaptée",
                          "densité de la loi normale adaptée",
                          "densité estimée de SP"),
       col=c("blue","red","black"),lty=1,cex=0.7)
```

La densité de normale adaptée et de Laplace adapté



On voit que la densité estimée de SP est plus proche de la densité de la loi de Laplace adaptée que de la densité de la loi normale adaptée. Mais exigeamment, SP ne suit pas une loi de Laplace, on doit chercher l'autre loi pour une estimation plus précise.